DAH 2026
PRELIMINARY · v2.0

DEFENSE AI CYBER SECURITY HACKATHON · PRELIMINARY TECHNICAL REPORT

UAV/UGV 공격 시나리오 대응 방어 AI 시스템 설계

위성망 모사 클라우드 환경에서의 다중 에이전트 기반 탐지–대응–복원(Detect–Respond–Recover) 아키텍처

— 위협모델 형식화 · 관련연구 비교 · 평가 프로토콜 포함 —

제출 부문	대상 환경	일자
방산 AI 공방전 · 예선 보고서 v2	UAV / UGV · SATCOM 모사 Cloud	2026.07 (예선 마감 기준)

Executive Summary

본 보고서는 DAH 2026 예선 심사 배점표(공격 시나리오 30점, 방어 전략 25점, AI 에이전트 아키텍처 25점, 팀 역량 10점, 문서 완성도 10점)에 정합하도록 작성되었다. 본선 채점식 $S = (A + D) \cdot \alpha$ — 여기서 α는 가용성(0–1) — 는 단순한 침투/차단 능력이 아니라 *임무 지속성(Mission Assurance)*을 평가하며, 이는 NIST SP 800-160 Vol.2의 사이버 회복탄력성 원칙 [5]과 정합한다. 따라서 본 시스템의 모든 설계 결정은 가용성 보존을 일차 제약(primary constraint)으로 둔다.

본 보고서의 명시적 기여 (Contributions)

1. **도메인 정합 위협모델** — UAV/UGV의 4중 공격 표면(RF/EM, 버스/프로토콜, 컴퓨트/OS, 인지/AI)을 형식화하고, MITRE ATT&CK for ICS [1] · ATLAS [2] 기법을 10개 본선 시나리오에 일대일 매핑.
2. **가용성-인지(availability-aware) 대응 학습** — 행동공간 각 액션에 가용성 비용 함수 $c_{avail}(a)$를 부여하고, 채점식 곱셈 구조와 동일한 형태의 강화학습 보상으로 학습. 오프라인 단계는 Conservative Q-Learning [9]으로 안전 우선 정책을 확보.
3. **이중 사고 다중 에이전트 구조** — System-1(경량 ML 분류기)과 System-2(LLM ReAct [10])를 분리하여 SATCOM RTT 600–800 ms 환경에서의 지연 예산을 만족. 4역할(Sentinel · Hunter · Healer · Coordinator)로 SOC 운영 모델을 모방.
4. **안전성 보증 — Safety Shield** — RL 정책 출력을 BTL(Boolean Temporal Logic) 규칙으로 후필터링하여 임무영역 이탈·대량 격리·세이프홀드 오남용을 정형적으로 금지(DARPA HACMS [28]의 정형검증 원칙 차용).

정량 목표

공격 점수 ≥ 70%, 방어 차단율 ≥ 85%, 가용성 ≥ 95% 유지
(관측 윈도우 = 본선 라운드 전체).

지연 예산

Sentinel ≤ 50 ms · Hunter(LLM) ≤ 1.5 s · Healer ≤ 200 ms.
SATCOM RTT 800 ms 대비 헤드룸 ≥ 30%.

실증 범위

PX4 SITL + Gazebo Garden 시뮬레이션. SDR/실기 시험은 본선 진출 후 NDA 범위로 분리.

목차

1. 서론 — UAV/UGV 사이버보안 패러다임 · 본 보고서 범위
2. 위협모델 — 형식화된 적·신뢰 가정·보안 목표
3. 관련 연구 — Prior Work 비교 및 차별점
4. 공격 표면 매핑 — MITRE ATT&CK / ATLAS / STRIDE
5. 공격 시나리오 설계 (10건)
6. 방어 전략 — Defense-in-Depth × Zero Trust × Resilient Control
7. AI 방어 에이전트 아키텍처
8. 채점식 최적화 — 가용성 보존 보상
9. 계획된 평가 프로토콜(Planned Evaluation)
10. 한계(Limitations)
11. 책임공개 · 윤리 · NDA
12. 구현 로드맵 · 리스크
13. 팀 역량 및 운영
14. 부록 A — 참고문헌 / 부록 B — 약어 / 부록 C — 한국 방산 사이버보안 표준

1. 서론 — UAV/UGV 사이버보안 패러다임

1.1 문제 정의

현대 무인이동체(UAV/UGV)는 통신·항법·제어·인지가 단일 임베디드 스택 내에서 결합되어 동작하는 사이버-물리 시스템(CPS)이며, 공격 표면이 (i) **RF/전자기**(GNSS, SATCOM, 데이터링크), (ii) **버스/프로토콜**(CAN, MIL-STD-1553B [14], MAVLink 2.0 [17], STANAG 4586 [13]), (iii) **컴퓨트/OS**(RTOS, Linux, 컨테이너), (iv) **인지/AI**(비전·LiDAR·강화학습 정책)로 4중화되어 있다. 작전 템포에서 사람이 4표면을 동시에 다루는 것은 비현실적이며, 판단 지연(latency) 자체가 패배 요인이다 — DAH 2026이 *AI 에이전트 간 자율 공방*을 요구하는 까닭이다.

1.2 본 보고서의 범위(Scope)

- **In-Scope**: 본선 환경(클라우드 기반 위성망 모사 + UAV/UGV 시뮬레이션)에서 동작하는 AI 공격/방어 에이전트 설계.
- **Out-of-Scope**: (i) 실기 비행 또는 실제 SATCOM 단말에 대한 SDR 공격 PoC, (ii) 특정 비공개 제품의 0-day, (iii) 무기체계 인증 시험(KCMVP, CC) 결과. 이들은 본선 진출 후 NDA 범위 내에서 별도 산출물로 분리한다.

1.3 설계 원칙 (Principles)

#	원칙	출처	본 설계 적용
P1	Defense-in-Depth	NIST SP 800-82r3 [3]	RF/Bus/Compute/AI 4계층 모두에 탐지·차단 배치
P2	Zero Trust Architecture	NIST SP 800-207 [4]	모든 MAVLink/DDS 메시지를 ID 토큰 + 정책 검사
P3	Cyber Resilience	NIST SP 800-160 Vol.2 [5]	3-모드 자동 페일오버(Normal / Degraded / Safe-Hold)
P4	AI Risk Management	NIST AI RMF 1.0 [7]	적대적 입력 탐지 + 모달리티 일관성 검증
P5	Mission Assurance	MIL-HDBK-1785 [15], DoDI 8500.01 [16]	RL 보상에 c_{avail} 직접 반영
P6	System Security Engineering	NIST SP 800-160 Vol.1 [6]	위협-기능-시험의 추적성(Traceability) 매트릭스 유지

2. 위협모델 (Threat Model)

본 절은 보안 분석의 출발점인 적(adversary), 신뢰 가정, 보안 목표를 형식화한다. 학회 관례에 따라 정의(Definition)-속성(Property) 형태로 기술한다.

2.1 적 모델 (Adversary Model)

Definition 2.1 — 적의 능력 집합 C

본 보고서는 적 A의 능력을 다음 7원소 튜플로 정의한다: $C = (c_{RF}, c_{BUS}, c_{OS}, c_{AI}, c_{SUP}, c_{OBS}, c_{COMP}) \in \{0,1,2\}^7$, 여기서 0=불가, 1=수동(passive), 2=능동(active). 본선 표준 위협은 $C^* = (2,2,1,2,1,2,2)$ — 즉 능동 RF/버스/AI 공격이 가능한 Tier-1 행위자.

Definition 2.2 — 적의 지식 가정

적은 *Kerckhoffs 원칙*에 따라 시스템 설계·소스 코드를 알고 있으며(open-design adversary), 암호 키와 임무 계획 토큰만이 비밀이다. 적은 신호 변조 후 발사·청취가 가능하며(SDR 등가), 암호계에 대해 다항시간 계산능력(PPT)을 갖는다.

Definition 2.3 — 적의 목표 g ∈ G

$G = \{g_{div}(\text{임무이탈}), g_{loss}(\text{기체손실}), g_{exfil}(\text{정보탈취}), g_{denial}(\text{가용성저하})\}$. 채점식 관점에서 적은 자신의 공격 점수 A를 극대화하면서 방어 측 가용성 α_D를 동시에 떨어뜨리는 결합 목표를 갖는다.

2.2 신뢰 가정 (Trust Assumptions)

1. **TA1** — 본선 클라우드 인프라(쿠버네티스 컨트롤플레인, 시뮬레이터)는 신뢰된다. 공격은 사용자 네임스페이스 내부에서만 발생.
2. **TA2** — Secure Boot 측정 체인의 루트(RTM)는 TPM에 봉인되어 있으며, 첫 부팅 시 무결성이 검증된다 [8].
3. **TA3** — 인지 모델의 weights는 sigstore [20] 서명으로 무결성이 검증된 후 로드된다.
4. **TA4** — 위성망 RTT 분포는 정규성을 보이지 않으며, p95 ≤ 800 ms · p99 ≤ 1.2 s 로 가정.

2.3 보안 목표 (Security Goals)

ID	속성	형식 정의	측정 지표
SG1	임무 무결성	$\forall t$: pose(t) $\in$ MissionEnvelope	Envelope 위반율 $\leq$ 1%
SG2	명령 인증성	$\forall$cmd: Verify(σ, m, pk) = 1	위조 MAVLink 통과율 $\leq 10^{-3}$
SG3	가용성	$\alpha(t) \geq 0.95$ over windows of 60 s	SLA 미달 시간 비율
SG4	적대적 견고성	$\forall x$: $\lVert x'-x \rVert_\infty \leq \varepsilon \Rightarrow \pi(x')=\pi(x)$	PGD ε=8/255 시 정책 일치율
SG5	관측 가능성	모든 액션은 변조불가 로그를 가짐	로그 결손율 = 0

3. 관련 연구 (Related Work)

본 절은 UAV/UGV 사이버보안 및 AI 기반 자동 대응에 대한 선행 연구를 비교하고, 본 시스템의 차별점을 명시한다.

3.1 비교표

접근	대상	방어 자동화 수준	AI 사용	가용성 인지	본 시스템과의 차이
DARPA HACMS [28]	무인기 SW 정형검증	정적 검증 중심	없음	간접	HACMS는 설계 시 정형검증; 본 시스템은 런타임 다중 에이전트 대응
HoneyDrone [29]	드론 허니팟	탐지 위주	제한적	아니오	본 시스템은 능동 대응까지 포괄, 적대적 ML 위협 포함
Petit & Shladover 자율주행 위협조사 [30]	지상 AV	분석/조사	아니오	아니오	지상 AV 중심; 본 시스템은 항공·SATCOM 결합 시나리오
ART (IBM) [36] · Foolbox [37]	적대적 ML 도구	도구킷	예(공격/방어 평가)	아니오	본 시스템은 ART를 평가에 활용하되 운영 에이전트는 자체 설계
Cao et al. LiDAR 적대적 입력 [25]	자율주행 LiDAR	공격 시연	예	아니오	본 시스템은 다중 모달리티 일관성 검증으로 방어
Humphreys GPS 스푸핑 시리즈 [22]	GNSS	공격 시연	예	아니오	본 시스템은 INS 잔차 + 다위성군 교차검증으로 탐지
일반 SOAR(Security Orchestration, Automation, Response)	엔터프라이즈 IT	플레이북 기반	없음/낮음	아니오	본 시스템은 LLM ReAct + RL 적응형 대응, CPS 도메인 특화

3.2 차별 포인트 정리

1. **CPS-네이티브**: RF·버스·OS·AI 4계층 통합. 일반 IT SOAR과의 본질적 차이.
2. **가용성 보존 학습**: 보상 함수에 곱셈형 가용성 비용을 명시 — 채점식과 일치.
3. **이중 사고 분리**: 실시간 경로(System-1)와 추론 경로(System-2) 분리로 위성 RTT 제약 충족.
4. **정형 안전망**: BTL Safety Shield로 RL 정책 폭주 차단.

4. 공격 표면 매핑 — MITRE 정합

4.1 UAV/UGV 공격 표면 지도

```
RF/EM 표면     ┌──────────────────────────────────────────────────┐
               │ GNSS(GPS L1/L5, Galileo E1/E5)  ·  SATCOM(L/Ku/Ka)  │
               │ Telemetry/CDL  ·  Remote-ID  ·  Jam · Spoof · MITM  │
               └──────────────────────────────────────────────────┘
                                          │ 복조/디코딩
                                          ▼
버스/프로토콜  ┌──────────────────────────────────────────────────┐
               │ STANAG 4586 · MAVLink 2.0 · CAN(J1939) · 1553B · DDS │
               │ Mission Plan(XML/JSON)  ·  Time Sync(NTP/PTP)       │
               └──────────────────────────────────────────────────┘
                                          │ IPC/PubSub
                                          ▼
컴퓨트/OS      ┌──────────────────────────────────────────────────┐
               │ RTOS(VxWorks, INTEGRITY) · Linux(PREEMPT_RT)        │
               │ Containers(Podman) · Bootloader · TPM/Measured Boot │
               └──────────────────────────────────────────────────┘
                                          │ 센서 입력
                                          ▼
인지/AI 계층   ┌──────────────────────────────────────────────────┐
               │ Vision · LiDAR · Radar · SLAM · 정책망 π · 행동 결정 │
               └──────────────────────────────────────────────────┘
```

4.2 MITRE ATT&CK · ATLAS 정합 매트릭스

ID	매트릭스	기법	본 시나리오 매핑
T0830	ICS	Adversary-in-the-Middle	S-2 MAVLink C2 하이재킹
T0848	ICS	Rogue Master	S-7 1553B BC 위장
T0856	ICS	Spoof Reporting Message	S-1 GNSS · S-4 센서 기만
T0858	ICS	Change Operating Mode	S-8 스웜 합의 변조
T0813	ICS	Denial of Control	S-10 자원 고갈
T1557	Enterprise	AiTM	S-5 SATCOM MITM
T1542.003	Enterprise	Bootkit	S-3 펌웨어 변조
AML.T0015	ATLAS	Evade ML Model	S-6 정책망 회피
AML.T0043	ATLAS	Craft Adversarial Data	S-4 LiDAR 패치
AML.T0018	ATLAS	Backdoor ML Model	S-3 공급망 ML 트로이

4.3 STRIDE 분류

S(Spoofing)	T(Tampering)	R(Repudiation)	I(Info disclosure)	D(DoS)	E(EoP)
위성/지상국 신원 위장	MAVLink 페이로드 변조	로그 부재 / 명령 부인	임무계획 유출	RF 재밍 · CPU 고갈	RTOS root 권한 취득

5. 공격 시나리오 설계 (예선 배점 30점)

본 절은 본선 공방을 가정한 10개 시나리오로 구성된다. 각 시나리오는 **(1) 목표 → (2) 표면/경로 → (3) AI 에이전트 전략 → (4) 예상 방어 우회 → (5) 가용성 영향**의 5요소로 기술한다. 모든 시나리오는 (i) 방어 측 점수를 직접 깎거나, (ii) 가용성 계수를 직접 떨어뜨리거나, (iii) 자해형 오탐을 유도하도록 설계되었다.

S-1 · GNSS 스푸핑/재밍 (위성항법 기만)

목표

비행체 위치 추정을 점진 이격(drag-off) — 임무 좌표 이탈 유도.

근거

Humphreys et al. [22]의 yacht 실증 — 칼만필터 잔차 임계 미만으로 좌표를 끌어내는 attack.

AI 전략

RL로 잔차 임계 미만 오프셋 schedule 학습. 본선에서는 시뮬레이터의 GNSS 토픽 변조로 모사.

우회 포인트

RAIM 단일 임계 IDS, 단일 위성군 의존

가용성 영향

중(비행 지속, 좌표만 이탈) → **채점 친화적**

탐지 신호

C/N0 분포 이상 + 단일 위성 도플러 일치도 + INS-GNSS 잔차 시계열

S-2 · MAVLink 2.0 C2 하이재킹 (AiTM, T0830 [1])

MAVLink 2.0은 HMAC 기반 메시지 서명을 도입하였으나 [17], PSK 운영 시 키 회전 주기·재생 보호가 약하다는 점이 다수 보안 연구에서 지적되어 왔다. 공격 에이전트는 위성 게이트웨이에서 (i) `HEARTBEAT` 시퀀스를 학습, (ii) 정상 트래픽 사이에 `COMMAND_LONG`(`MAV_CMD_DO_REPOSITION`·`MAV_CMD_DO_SET_MODE`)을 인젝션, (iii) `STATUSTEXT`를 위조하여 지상국 로그를 오염시킨다.

> 방어 우회: 키 회전 주기가 긴 운영(예: ≥ 5 min)인 경우, LLM 에이전트가 시퀀스 회귀로 회전 시점을 추정 → 회전 직전 윈도우에 인젝션 집중.

S-3 · 펌웨어/공급망 변조 (T1542.003 · AML.T0018)

- **Bootkit**: Secure Boot 미적용 부트로더 영역에 부팅 시 메모리 패치 삽입 [1].
- **ML Trojan**: 인지 모델에 트리거 패턴 반응 백도어 삽입(ATLAS AML.T0018 [2]; 학술적 토대는 Gu et al. [24]의 BadNets).
- **대회 환경**: 컨테이너 이미지 레지스트리에 변조 layer 주입 — sigstore [20] 미적용 시 가능.

S-4 · 센서 적대적 입력 (LiDAR/Camera Adversarial, AML.T0043)

경계 인식 모델의 출력을 변조하기 위해 (i) 카메라에 대해 적대적 패치(텍스처)를 환경에 배치 — Eykholt et al. [26]의 물리적 적대적 예제 원리, (ii) LiDAR에 대해 가짜 점군을 인젝션 — Cao et al. CCS 2019 [25] · Tu et al. CVPR 2020 [27]. 본 대회의 시뮬레이션 환경에서는 노이즈 토픽을 직접 발행한다.

S-5 · SATCOM MITM (위성 링크 중간자, T1557)

모사된 위성 게이트웨이 사이에 프록시를 설치 — (i) STANAG 4586 LOI(Level of Interoperability) 메시지의 우선순위 필드를 변조 [13], (ii) NTP 응답을 지연시켜 비행체 시간 동기를 흔든다. 시간 동기 흔들기는 후속 공격 S-2의 서명 재생 윈도우를 확장시키는 *전제 공격(precursor)*이다.

S-6 · AI 정책망 회피 (AML.T0015 · 적대적 RL 입력)

강화학습 항로 결정망 $\pi(s)$의 관측 s에 적대적 노이즈를 가하여 선회 결정을 왜곡한다. Madry et al. [12]의 PGD 기반 위협 모델을 RL 관측 공간으로 확장하며, 공격 에이전트는 *가용성 영향 없이 결정만 흔드는 노이즈 부위*를 LLM으로 추론한 후 RL로 미세조정한다.

S-7 · CAN / MIL-STD-1553B 메시지 인젝션 (UGV)

UGV의 구동/조향 명령은 CAN(J1939 [19]) 또는 1553B [14]로 흐른다. RT(원격 단말)를 BC(Bus Controller)로 위장하는 *Rogue BC*(T0848) 패턴으로 가짜 조향각·스로틀 명령을 주기적으로 주입한다. 단발성이 아닌 저강도 지속(low-and-slow) 패턴으로 IDS 평균선을 회피.

S-8 · 스웜 합의 알고리즘 공격

다수 UAV의 합의(consensus) 기반 편대에서 비잔틴 노드 1대가 거짓 위치·잔량 정보를 방송 — 평균 기반 합의에서 1/3 미만 오염으로 편대 이탈 유도. 이는 Lamport et al.의 비잔틴 합의 이론 영역과 결합된 CPS 공격이다.

S-9 · 사이드채널 키 추출

전력/EM 분석으로 AES·ECDSA 키 추출. 대회 환경에서는 cgroup 카운터를 통한 timing 분석으로 모사. 학술적으로 Kocher et al.의 분석군 계보를 따른다.

S-10 · 자원 고갈 DoS — 방어 자해(self-DoS) 유도 고위험

방어 측의 IDS 룰이 과적재된 시점을 노려 *의도적 false positive 유발 트래픽*을 송출하여 SIEM 큐를 폭주시킨다. 역설적으로 방어 측 가용성 계수를 떨어뜨리도록 유도하는 자해 유도형. 채점식 곱셈 항을 직접 공격하는 가장 채점 친화적 시나리오.

시나리오 우선순위 매트릭스

#	공격 점수 기여	방어 회피 난이도	가용성 친화도	본선 권장 우선순위
S-1	높음	중	**높음**	★★★★★
S-2	매우 높음	중-상	중	★★★★★
S-3	중	상	중	★★★
S-4	높음	중	높음	★★★★
S-5	중	중	높음	★★★★
S-6	높음	상	**매우 높음**	★★★★★
S-7	높음	중	중	★★★★
S-8	중-상	상	중	★★★
S-9	중	매우상	높음	★★
S-10	중	중	**방어 자해 유도**	★★★★★

6. 방어 전략 (예선 배점 25점)

본 절은 **Defense-in-Depth × Zero Trust × Resilient Control**의 3축을 결합한 통합 방어 모델을 제시한다. MITRE D3FEND [D] 기술군과 정합되도록 매핑한다.

6.1 4-계층 Defense-in-Depth

```
┌──────────── L4 인지/AI ────────────┐   적대적 입력 탐지 · 모달리티 가중 · Safety Shield
│     (Vision, LiDAR, Policy π)      │   D3-MAID, D3-EI, D3-FA
├──────────── L3 컴퓨트/OS ──────────┤   Secure Boot · TPM · eBPF/Falco · sigstore
│   (RTOS, Linux, Container)         │   D3-PSEP, D3-RTSD
├──────────── L2 버스/프로토콜 ──────┤   MAVLink 서명 강화 · DDS-Security · 1553B IDS
│   (MAVLink, DDS, CAN, 1553B)       │   D3-MA, D3-NTA
├──────────── L1 RF/EM ──────────────┤   GNSS 다군 교차검증 · 빔포밍 · Spoof 탐지
│   (GNSS, SATCOM, Data-Link)        │   D3-EI (sensor anomaly)
└────────────────────────────────────┘
```

L1 — RF/EM 계층

- **GNSS 다군 교차검증**: GPS L1/L5 · Galileo E1/E5 · KASS SBAS 다중 위성군의 위치·시간 해를 교차검증. RAIM [3]의 단일 임계가 아닌 잔차 + C/N0 분산 + 도플러 일치 + (가능 시) 도래각(AOA)의 다중 신호 합산으로 spoofing 탐지를 강화한다.
- **SATCOM Anti-Jam**: 적응적 부호화율(ACM) + 주파수 호핑(FHSS) 원리 — MIL-STD-188-141B [18] 등의 HF 보안 통신 모범을 참조 (본선은 모사 환경이라 원리만 채택).
- **Remote-ID 무결성**: 식별 메시지에 단조 시퀀스 + 서명 검사.

L2 — 버스/프로토콜 계층

- **MAVLink 2.0 Hardening**: HMAC-SHA256 서명 [17] + 시퀀스 재생 보호 + *키 회전 ≤ 30 s* + 단조증가 `timestamp` 강제.
- **DDS-Security v1.1** [18b]: Authentication / Access Control / Cryptographic 3 플러그인 활성화, 토픽 단위 권한 분리.
- **1553B 행위 IDS**: BC의 RT-RT 통신 패턴 시계열 학습 → Rogue BC 탐지.
- **CAN J1939 이상 탐지**: PGN 단위 정상 시계열 학습 — 이상 PGN 발생 시 Healer 에이전트에 즉시 보고.

L3 — 컴퓨트/OS 계층

- **Measured Boot + TPM**: PCR 측정값 검증, Secure Boot 실패 시 세이프모드. NIST SP 800-193 [8]의 PFR 원칙.
- **eBPF 런타임 가시성**: Tetragon [34]·Falco [33]로 syscall·network·file 이벤트 4 ms 단위 수집.
- **컨테이너 무결성**: cosign/sigstore [20] 검증 후 실행.
- **최소 권한**: 미션 컨트롤은 `CAP_NET_RAW` 거부, 게이트웨이 분리.

L4 — 인지/AI 계층

- **적대적 입력 탐지**: feature squeezing + Mahalanobis OOD 점수 + 모달리티 일관성(LiDAR↔Camera IoU) 교차검증 [25].
- **정책망 안전망 (Safety Shield)**: RL 행동 a를 정형 검증 BTL 규칙으로 후필터링 — HACMS의 정형검증 정신을 운영 단계로 이전 [28].
- **모델 무결성**: weights 해시 검증, MLOps 데이터 lineage 보존(NIST AI RMF 1.0 [7]).

6.2 Zero Trust for Tactical Edge

NIST SP 800-207 [4] 원칙을 무인이동체 환경에 적용. 핵심 — *네트워크 위치는 신뢰의 근거가 아니다.* 모든 MAVLink/DDS 메시지는 5속성을 검사받는다 — 발신자 ID(SPIFFE-style 토큰 [19b]), 메시지 정책, 시간 무결성, 시퀀스 무결성, 컨텍스트(임무 단계).

6.3 Resilient Control — 3-Mode

모드	트리거	행동	가용성 영향
Normal	모든 지표 정상	풀 자율 비행	α=1.00
Degraded	L1/L2 이상 감지	임무 유지 + 검증 강화 + 보조 채널 우선	α≥0.95
Safe-Hold	L3/L4 위협 확정	호버/정지 + 사전 검증 좌표만 수신	α≈0.6–0.8

6.4 KPI

- MTTD ≤ 2.5 s (위성 RTT 고려) · MTTR ≤ 5.0 s · FPR ≤ 1% · α ≥ 0.95.

7. AI 방어 에이전트 아키텍처 (예선 배점 25점)

7.1 설계 원칙

1. **역할 분리**: 단일 LLM 만능 에이전트가 아니라 *4역할*의 다중 에이전트(SOC 모방).
2. **이중 사고**: *System-1*(빠른 ML 분류기·RL 정책) + *System-2*(느린 LLM 추론) — Kahneman의 사고 분리 차용 [31].
3. **도구 사용**: 모든 에이전트는 표준 도구 인터페이스(eBPF, Suricata [32], Falco, OpenZiti [35], MAVLink-proxy) 호출 가능.
4. **설명가능성**: 모든 결정은 *Reasoning Trace*를 남김(사후 NDA 감사 대비).
5. **비용 함수 일치**: 보상 $R = (\Delta A + \Delta D)\cdot\alpha - \lambda_a \cdot c_{avail} - \lambda_f \cdot \mathbb{1}[FP]$ — 채점식 곱셈 효과 직반영.

7.2 4역할 에이전트

Sentinel — Detection (System-1)

eBPF + Suricata + 인지 OOD 검출기의 신호를 1차 분류. GBDT + Isolation Forest + LSTM-VAE 앙상블. 초당 수천 이벤트 처리, *의심 토큰*을 Hunter로 발행.
지연 예산: ≤ 50 ms.

Hunter — Reasoning (System-2, LLM)

ReAct 루프 [10] — 의심 토큰 + 컨텍스트를 받아 *가설 → 도구 호출 → 결론*. Tool list: `query_ebpf`, `diff_mavlink_signature`, `compare_lidar_camera` 등.
지연 예산: ≤ 1.5 s (비실시간 경로).

Healer — Response (RL 정책)

RL 정책망 $\pi_H(s)$. 행동공간 = {block, isolate, rollback, mode-shift, no-op}. 보상은 가용성 인지 형태(아래 7.4).
지연 예산: ≤ 200 ms.

Coordinator — Policy (LLM, short-context)

임무 단계(이륙·순항·표적·복귀)별 정책 매트릭스 적용. 3 에이전트의 결정 충돌 조정.
지연 예산: ≤ 500 ms.

7.3 시스템 아키텍처

```
┌──────────────────────────────────────────────────────────┐
│                  Mission Plan / RoE Policy                  │
└──────────────────────────────────────────────────────────┘
                              │
                              ▼
┌──────────────────────────────────────────────────────────┐
│                       Coordinator (LLM)                     │
│              – 임무 단계 인지 · 정책 조율 · 충돌 해소 –        │
└──────────────────────────────────────────────────────────┘
        │              │              │
        ▼              ▼              ▼
┌──────────┐    ┌──────────┐    ┌──────────┐
│ Sentinel │    │  Hunter  │    │  Healer  │
│ (ML 앙상블) │    │   (LLM)  │    │  (RL π)  │
└──────────┘    └──────────┘    └──────────┘
```

```
                    │                │                │
Telemetry/Logs│      Tool Calls (eBPF/Suricata/Proxy)   Mitigation Actions
                    │                │                │
              ┌─────▼────────────────▼────────────────▼──────┐
              │              Data Plane (UAV/UGV)            │
              │   L1 RF · L2 Bus · L3 OS · L4 Perception     │
              └──────────────────────────────────────────────┘
```

7.4 형식 정의 — Observation · Action · Reward

Definition 7.1 — 관측 공간 S

$S = S_{RF} \times S_{BUS} \times S_{COG} \times S_{MIS} \times S_{SCORE}$. 각 부분공간의 원소는 7.5의 코드 정의 참조.

Definition 7.2 — 행동 공간 A 와 가용성 비용 c_{avail}

$A = \{a_1,\ldots,a_7\}$, $c_{avail}: A \to [0,1]$ (7.5의 표).

Definition 7.3 — 보상

$R_t = (\Delta A_t + \Delta D_t)\cdot\alpha_t - \lambda_a \cdot c_{avail}(a_t) - \lambda_f \mathbb{1}[a_t \text{가 FP 유발}]$. 본 설계 $\lambda_a=0.6, \lambda_f=0.8$로 시작하여 도메인 무작위화 환경에서 grid search.

Definition 7.4 — OOD 점수

특징 분포 $\mathcal{N}(\mu,\Sigma)$에 대한 Mahalanobis 거리 $d_M(x) = \sqrt{(x-\mu)^T \Sigma^{-1} (x-\mu)}$가 τ를 넘으면 OOD로 분류. τ는 검증셋의 99-퍼센타일.

7.5 Observation / Action 코드 정의

```
# Observation s_t
s_t = {
  rf:        {gnss_residual, cn0_var, sat_drift_rate, doppler_consistency},
  bus:       {mavlink_sig_fail_rate, dds_acl_deny_rate, can_anomaly_score},
  compute:   {syscall_kl_div, file_integrity_violations, cpu_throttle_ms},
  cognition: {lidar_camera_iou, ood_score, policy_entropy_delta},
  mission:   {phase, time_to_waypoint, fuel_pct},
  scoreboard:{availability_pct, attack_pts, defense_pts}
}

# Action A (가용성 영향 비용 c_avail 동시 명시)
A = [
  ("no_op",                   c_avail=0.00),
  ("rotate_mavlink_key",      c_avail=0.02),
  ("isolate_compromised_pod", c_avail=0.10),
  ("switch_modality_weight",  c_avail=0.05),
  ("enter_safe_hold",         c_avail=0.35),
  ("rollback_firmware",       c_avail=0.45),
  ("kill_suspect_link",       c_avail=0.20),
]

# 보상 (Definition 7.3 구현)
R_t = (delta_attack + delta_defense) * (availability_t / 100.0) \
      - lambda_a * c_avail(a_t) \
      - lambda_f * false_positive_indicator
```

7.6 Hunter LLM의 ReAct 사이클 — 예시

```
# 예: S-2 MAVLink 인젝션 의심
Thought: HEARTBEAT 시퀀스 누락 + COMMAND_LONG 빈도 급증. MITM 가능성 평가 필요.
Action:  query_ebpf(filter="mavsdk_proxy ingress 5s", fields="src,seq,sig_ok")
Obs:     56 packets, sig_ok=false: 31, src_anomaly: 22
Thought: 서명 실패율 55% > 임계 5%. S-2 강한 신호. 가용성 영향 최소 대응 탐색.
Action:  propose_action(candidates=["rotate_mavlink_key","kill_suspect_link"])
Obs:     rotate_key c_avail=0.02, kill_link c_avail=0.20
Thought: rotate_key 우선, 5초 내 회복 없을 시 kill_link 에스컬레이션.
Final:   handoff_to_healer(plan="rotate_key -> observe(5s) -> escalate")
```

7.7 지연 예산 분석

경로	구성 요소	예산	총합
실시간(System-1)	Sentinel(50 ms) + Healer(200 ms)	250 ms	≤ 250 ms (RTT p50 ≈ 600 ms 내부 처리)
비실시간 (System-2)	Hunter LLM(1500 ms) + Coordinator(500 ms)	2 s	의사결정 escalation 경로
최악	SATCOM p99 + 처리	1.2 + 0.25 s	1.45 s ≤ 임무 안전 마진

7.8 학습 파이프라인

- **Pre-train**: MITRE ATT&CK + ATLAS 시나리오 시뮬레이터에서 1000+ 에피소드.
- **Offline RL**: Conservative Q-Learning [9]로 안전 우선 정책 학습.
- **Online RLHF/RLAIF**: 시뮬레이션 내 상위 LLM의 행동 피드백.
- **Continual**: 본선 적응 시 Federated 방식 가중치 집계 — raw 데이터 미전송.

7.9 Safety Shield (정형 안전망)

RL 정책의 출력은 항상 BTL 규칙 셋을 통과한다 — (i) 임무 영역 1.5 km 이탈 행동 금지(SG1), (ii) 동시 isolate ≥ 3건 금지(자해 방지), (iii) Safe-Hold 전환은 Coordinator 동의 필수. 이 규칙들은 모델 검증기(NuSMV 등) 등가의 표현식으로 사전 검증된다.

8. 채점식 최적화 — 가용성 보존

```
A=70, D=80, α=1.00 → S = 150 × 1.00 = 150.0
A=90, D=95, α=0.70 → S = 185 × 0.70 = 129.5
A=60, D=70, α=1.00 → S = 130 × 1.00 = 130.0
```

같은 (A+D) 합계에서도 α 30%pt 손실 = 점수 30% 손실. 본 시스템은 액션마다 c_{avail}를 부여하고, Healer 정책은 *저영향 대응 우선* 학습된다. 예: "전체 차단" 대신 "키 회전 + 5 s 관찰 윈도우" 후 필요 시 에스컬레이션.

8.1 본선 라운드 운영 전략

1. **초반 5분**: 공격은 S-1/S-5 같은 저영향 시나리오로 점수 누적. 방어는 baseline α=1.0 유지.
2. **중반**: S-2/S-7 본격 침투. Healer는 키 회전 + 격리 1건 정도로 응대.
3. **후반**: S-10(자해 유도) 회피 — IDS 룰 임계를 동적으로 완화하여 SIEM 큐 폭주 방지.

9. 계획된 평가 프로토콜 (Planned Evaluation)

본 보고서 시점에서 실측 결과는 제시하지 않는다(예선 단계). 본 절은 향후 평가의 형식적 프로토콜을 명시함으로써 재현성과 학술적 검증가능성을 확보한다.

9.1 환경

- PX4 SITL v1.14 × Gazebo Garden × MAVSDK [38] (UAV).
- ROS 2 Iron × DDS(RTI Connext 또는 Fast-DDS) (UGV).
- 위성망 모사 — Linux `tc-netem` 으로 RTT/jitter/loss 주입 (p50=600 ms, p95=800 ms).
- 적대적 ML 평가 — IBM ART [36], Foolbox [37].

9.2 평가 지표 (Definitions)

지표	정의	목표
MTTD	이벤트 발생 → Sentinel 경보 평균 시간	≤ 2.5 s (95% CI)
MTTR	경보 → Healer 액션 완료 평균 시간	≤ 5.0 s
FPR	정상 트래픽 100k 건당 오탐	≤ 1.0%
TPR	주입 공격 1k 건당 탐지	≥ 95%
α(window=60 s)	SLA 미달 비율의 1-보수	≥ 0.95
$\bar{R}$	에피소드당 평균 보상(Def 7.3)	baseline 대비 +30%

9.3 통계적 방법론

- 각 시나리오 30회 반복(seed 변경) — t-test 또는 Wilcoxon signed-rank로 baseline 대비 유의성 검정.
- 95% 신뢰구간 보고. 효과크기 Cohen's d 동시 보고.
- 적대적 견고성은 PGD ε=8/255, step=10, α=2/255 표준 설정.

9.4 비교 baseline

1. **B0** — 룰 기반 단일 IDS(Suricata only).
2. **B1** — Sentinel만(ML 탐지) + 정적 응대(블록).
3. **B2** — 본 시스템(Sentinel + Hunter + Healer + Coordinator).

9.5 재현성 (Reproducibility)

- 모든 실험 코드·시드·하이퍼파라미터는 본선 진출 후 NDA 범위 내에서 사내 git LFS + DVC로 보존.
- 로그 형식은 OpenTelemetry 호환.

10. 한계 (Limitations)

1. **시뮬레이션 격차** — PX4 SITL은 실기와 환경 모델·시계열 노이즈에서 차이를 보인다. 본선 결과는 실기 작전 성능을 직접 보증하지 않는다.
2. **실제 SATCOM 비포함** — 본 시스템은 위성망 모사 환경을 대상으로 한다. 실 SATCOM 단말의 물리·링크 계층 공격(빔 재밍, 트랜스폰더 공격)은 별도 평가가 필요하다.
3. **LLM 추론 비용** — Hunter 사이클에는 외부 또는 자체호스팅 LLM이 필요하며, 본선 환경 외부 호출은 NDA·보안 정책 상 제한될 수 있다. 자체호스팅 모델(예: 7B–14B 양자화)로 대체할 계획.
4. **RL 일반화** — 도메인 무작위화로 완화하지만, 본선 환경 미공개 시나리오에 대해서는 분포 외(out-of-distribution) 행동 위험이 남는다. Safety Shield가 최후 보루다.
5. **적대적 견고성의 형식적 한계** — PGD 견고성은 ε 한계 내 보증에 불과하며, 미관측 공격 클래스에 대한 완전 견고성은 학계 미해결 문제다(Madry et al. [12]; 후속 연구 다수).
6. **운영 윤리** — 무인무기체계의 자율 의사결정 범위는 인간 책임(Human-on-the-loop)을 전제로 한다. 본 설계의 자율 대응은 사이버 방어(시스템 보호) 한정이며, 운동 키네틱 결정(가령 발사·교전)에는 적용하지 않는다.

11. 책임 공개 · 윤리 · NDA

- 본 보고서는 공개 표준·학술 문헌·오픈소스 자료에 근거하며, 특정 비공개 시스템의 0-day 또는 실증 익스플로잇 코드는 포함하지 않는다.
- 본선 진출 시 NDA 정식 서명 후, 비공개 PoC·로그·취약점 정보는 별도 산출물로 통제 환경에서만 공유한다.
- 대회 종료 후 1년간 비밀유지 의무를 준수하며, 외부 공개는 LIG D&A의 서면 동의 하에 추진한다.
- 본 시스템은 *방어(defensive)* 목적으로 설계되었으며, 공격 시나리오는 평가용 시뮬레이션에 한정된다 (MITRE ATT&CK의 평가 활용 원칙과 정합).

12. 구현 로드맵 · 리스크

12.1 마일스톤

주차	마일스톤	산출물
W1–W2	위협 모델 확정 · 시뮬레이터 셋업	위협 매트릭스, 환경 docker-compose
W3–W4	Sentinel · Hunter v0.1 · 5개 시나리오 시연	예선 보고서 v2
W5–W6	Healer RL 학습 · Safety Shield 검증	RL 정책 weights, 룰 셋
W7	본선 환경 적응 · Federated 가중치 동기화	적응 후 모델
W8	본선 리허설 · 가용성 튜닝	최종 산출물

12.2 리스크 · 완화

리스크	영향	완화책
LLM 추론 지연 > SATCOM RTT	Hunter 지연 → 가용성 손실	Sentinel 사전분류 + Hunter는 비실시간 경로만
RL 과적합	본선 환경 미스매치	CQL + 도메인 무작위화 + 다양한 시드
오탐 폭주	가용성 직접 손실	λ_f 적극 부여 + Safety Shield 동시 격리 금지
NDA 감사	제출 기각	Reasoning Trace · Tool Log 보존 · 외부 모델 호출 금지
외부 LLM 의존	본선 외부 호출 차단	자체호스팅 7B–14B 양자화 모델로 대체 가능

13. 팀 역량 및 운영 (예선 배점 10점)

※ 본 항목은 팀 결성 후 실명·이력으로 교체하여 최종 제출됩니다. 아래는 권장 구성 템플릿.

역할	전문 영역	책임	요구 역량 예시
팀장	방산·시스템 보안	위협 모델, NDA, 통합	NIST SP 800-82, MIL-STD 경험
AI 엔지니어	LLM · Agent · RL	Hunter LLM, Healer RL	ReAct·RLHF·CQL 구현 경험
플랫폼 엔지니어	Cloud · eBPF · 컨테이너	관측·격리·자동 복구	Tetragon·Falco·sigstore
RF/CPS 엔지니어	GNSS · SATCOM · MAVLink	L1·L2 시뮬레이터, PoC	PX4 SITL, MAVSDK, SDR

운영 체계

- 주 2회 stand-up + 주 1회 위협 리뷰.
- 모든 시뮬레이션 산출물 git LFS + DVC 버저닝.
- 본선 D-7부터 매일 풀 리허설.

부록 A — 참고 문헌

1. MITRE ATT&CK for ICS. attack.mitre.org/matrices/ics/
2. MITRE ATLAS — Adversarial Threat Landscape for AI Systems. atlas.mitre.org
3. NIST SP 800-82 Rev.3 (2023) — *Guide to Operational Technology Security*.
4. NIST SP 800-207 (2020) — *Zero Trust Architecture*.
5. NIST SP 800-160 Vol.2 Rev.1 (2021) — *Developing Cyber-Resilient Systems*.
6. NIST SP 800-160 Vol.1 Rev.1 (2022) — *Engineering Trustworthy Secure Systems*.
7. NIST AI RMF 1.0 (2023) — *Artificial Intelligence Risk Management Framework*.
8. NIST SP 800-193 (2018) — *Platform Firmware Resiliency Guidelines*.
9. Kumar A. et al. (2020) — *Conservative Q-Learning for Offline Reinforcement Learning*, NeurIPS 2020.
10. Yao S. et al. (2023) — *ReAct: Synergizing Reasoning and Acting in Language Models*, ICLR 2023.
11. Goodfellow I., Shlens J., Szegedy C. (2015) — *Explaining and Harnessing Adversarial Examples*, ICLR 2015.
12. Madry A. et al. (2018) — *Towards Deep Learning Models Resistant to Adversarial Attacks*, ICLR 2018.
13. NATO STANAG 4586 — *Standard Interfaces of UAV Control System (UCS)*.
14. MIL-STD-1553B — *Digital Time Division Command/Response Multiplex Data Bus*.
15. MIL-HDBK-1785 — *System Security Engineering Program Management*.
16. DoDI 8500.01 — *Cybersecurity*.
17. MAVLink 2.0 Protocol Specification & Message Signing. mavlink.io
18. MIL-STD-188-141B — *Interoperability and Performance Standards for Medium and High Frequency Radio Systems*.
19. OMG DDS-Security v1.1 — *Authentication / AccessControl / Cryptographic Plugins*.
20. SAE J1939 — *Recommended Practice for a Serial Control and Communications Vehicle Network*.
21. SPIFFE/SPIRE — *Secure Production Identity Framework for Everyone*. spiffe.io
22. Sigstore/Cosign — *Container image signing and transparency log*. sigstore.dev
23. NIST IR 8270 — *Introduction to Cybersecurity for Commercial Satellite Operations*.
24. Humphreys T.E. et al. — *Assessing the Spoofing Threat: Development of a Portable GPS Civilian Spoofer* (ION GNSS 2008 및 후속 시리즈).
25. Kushner D. (2013) — *The Real Story of Stuxnet*, IEEE Spectrum.
26. Gu T., Dolan-Gavitt B., Garg S. (2017) — *BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain*, arXiv:1708.06733.
27. Cao Y. et al. (2019) — *Adversarial Sensor Attack on LiDAR-based Perception in Autonomous Driving*, ACM CCS 2019.
28. Eykholt K. et al. (2018) — *Robust Physical-World Attacks on Deep Learning Visual Classification*, CVPR 2018.
29. Tu J. et al. (2020) — *Physically Realizable Adversarial Examples for LiDAR Object Detection*, CVPR 2020.
30. Fisher K. et al. (2017) — *The HACMS program: using formal methods to eliminate exploitable bugs*, Phil. Trans. R. Soc. A.
31. Daubert J., Boopalan H., Mühlhäuser M., Vasilomanolakis E. — *HoneyDrone: a medium-interaction unmanned aerial vehicle honeypot*, IEEE NOMS 2018.

32. Petit J., Shladover S.E. (2015) — *Potential Cyberattacks on Automated Vehicles*, IEEE Trans. Intelligent Transportation Systems.
33. Kahneman D. (2011) — *Thinking, Fast and Slow*, Farrar, Straus and Giroux.
34. Suricata IDS — suricata.io
35. Falco — Cloud-Native Runtime Security — falco.org
36. Tetragon — eBPF-based Security Observability — tetragon.io
37. OpenZiti — Zero Trust Networking — openziti.io
38. IBM Adversarial Robustness Toolbox (ART) — github.com/Trusted-AI/adversarial-robustness-toolbox
39. Rauber J., Brendel W., Bethge M. — *Foolbox* — github.com/bethgelab/foolbox
40. PX4 SITL · Gazebo · MAVSDK — UAV 시뮬레이션 스택. px4.io · mavsdk.mavlink.io
41. MITRE D3FEND — *Cybersecurity Countermeasure Knowledge Graph*. d3fend.mitre.org
42. ENISA (2024) — *Drones — Cybersecurity Challenges in the Aviation Sector*.
43. U.S. CISA (2024) — *Cybersecurity Guidance: Chinese-Manufactured UAS*.
44. KISA — *드론 정보보호 가이드*, 한국인터넷진흥원.
45. 방위사업청 — *무기체계 사이버보안 시험평가 지침*.
46. 국가정보원 — *KCMVP(Korea Cryptographic Module Validation Program) 운영 지침*.
47. DTaQ(국방기술품질원) — *국방 정보보호 기술 동향 및 시험평가 가이드*.
48. TTA — *드론 통신 보안 관련 KS/TTA 표준* (TTAK.KO-12 시리즈 등).

부록 B — 약어 · 용어 정의

약어	풀이	약어	풀이
UAV	Unmanned Aerial Vehicle	UGV	Unmanned Ground Vehicle
CPS	Cyber-Physical System	GNSS	Global Navigation Satellite System
SATCOM	Satellite Communication	STANAG	Standardization Agreement (NATO)
MAVLink	Micro Air Vehicle Link	DDS	Data Distribution Service
ATT&CK	Adversarial Tactics, Techniques & Common Knowledge	ATLAS	Adversarial Threat Landscape for AI Systems
D3FEND	Defensive Countermeasure Knowledge Graph (MITRE)	RAIM	Receiver Autonomous Integrity Monitoring
SOC	Security Operations Center	IDS	Intrusion Detection System
SLA	Service Level Agreement	MTTD/R	Mean Time to Detect / Respond
RL	Reinforcement Learning	LLM	Large Language Model
CQL	Conservative Q-Learning	OOD	Out-of-Distribution
eBPF	extended Berkeley Packet Filter	TPM	Trusted Platform Module
PEP/PE	Policy Enforcement Point / Engine	SPIFFE	Secure Production Identity Framework for Everyone
BTL	Boolean Temporal Logic	PGD	Projected Gradient Descent
KCMVP	Korea Cryptographic Module Validation Program	DTaQ	국방기술품질원
KISA	한국인터넷진흥원	SBOM	Software Bill of Materials

부록 C — 한국 방산 사이버보안 표준 / 컨텍스트

본 부록은 본 보고서의 한국 도메인 정합성을 보강하기 위한 표준·지침의 인용 모음이다. 일부 항목은 발간 시점·개정 이력에 따라 명칭이 달라질 수 있다.

C.1 무기체계 사이버보안 — 정부 지침

- **방위사업청** — *무기체계 사이버보안 시험평가 지침*(개정 이력 다수) [42]. 무기체계 R&D 단계(개념·체계·양산)별 정보보호 요구사항·시험평가 절차 규정.
- **합동참모본부** — 국방 사이버 작전 교범(상당 부분 대외비). 본 시스템의 운영 단계 정합성을 위해 공개 부분만 참조.
- **국가정보원** — *국가·공공기관 정보보호 기본지침* 및 KCMVP 운영 지침 [43]. KCMVP는 국정원 인증 암호 모듈 사용을 요구하며, 본 시스템의 키 관리·서명 모듈은 KCMVP 호환 모듈로 교체 가능한 설계.

C.2 방산·국방 시험평가

- **국방기술품질원(DTaQ)** — *국방 정보보호 기술 동향 및 시험평가 가이드* [44]. 소프트웨어 품질 시험과 정보보호 시험의 결합 평가 프로토콜.

C.3 민간 인프라 표준

- **KISA** — *드론 정보보호 가이드* [41] · SBOM 작성 가이드라인 · 5G/위성 융합 보안 가이드.
- **TTA** — TTAK.KO-12 시리즈 등 드론·무인이동체 통신 표준 [45].

C.4 한국 컨텍스트의 본 설계 정합성

본 시스템 요소	한국 표준 정합 포인트
MAVLink 서명 (HMAC-SHA256)	KCMVP 검증 암호모듈로 대체 가능 인터페이스
컨테이너 이미지 sigstore	KISA SBOM 가이드 정합 — 빌드 SBOM 자동 생성
로그·Reasoning Trace 보존	방사청 시험평가 추적성 요구 부합
Safety Shield (BTL)	DTaQ 정보보호 시험의 정형 검증 요구 흡수
임무 영역(SG1) 경계 강제	합참 운용 RoE의 시스템 강제(System Enforcement)

본 보고서(v2)는 DAH 2026 예선 보고서 작성 가이드(공격 시나리오 30 / 방어 25 / AI 에이전트 25 / 팀 역량 10 / 문서 완성도 10)에 정합하여 작성되었으며, 학회 워크숍 수준의 형식적 요소(명시적 기여 · 위협모델 형식화 · 관련연구 비교 · 평가 프로토콜 · 한계 · 책임공개)를 추가하였다. 모든 기술 내용은 공개 표준·학술 문헌·오픈소스 자료에 근거하며, 특정 시스템의 비공개 취약점·실증 익스플로잇 코드는 포함하지 않는다. 본선 진출 시 NDA 정식 서명 후 상세 PoC 산출물을 별도 제출한다.